

Guía de Señalizaciones Físicas + Comentarios para los Autores

Instrucciones: Imprime el artículo. Cada entrada indica **dónde** marcar, **qué** encerrar/subrayar, y el **comentario exacto** que debes escribir a mano en el margen. Al final, la lista de comentarios formales que enviarás a los autores.

SEÑALIZACIONES FÍSICAS (para escribir a mano sobre el papel)

1. Abstract — última frase

Dónde: Última oración del Abstract, la que dice "*antecedent-consequent recognition shows promise as a structural fingerprint for musical audio*".

Acción: Subráyala completamente.

Comentario al margen:

"El mejor MRR es 9.83% y el mejor Top-5 es 15%. Con Top-5 de 15%, el 85% de las queries falla. La afirmación 'shows promise as a fingerprint' está inflada respecto a la magnitud real. Reformular como prueba de concepto o bajar el tono de la conclusión."

2. Sección III.A — lista de los 8 extractores

Dónde: El listado numerado 1) al 8) de los extractores.

Acción: Encierra en un rectángulo los ítems 1 (pYIN), 6 (FCN-\$f_0\$) y 7 (pYIN+CREPE).

Comentario al margen:

"Los extractores comparados fueron diseñados para tareas distintas (monofónicos, polifónicos, habla — FCN-\$f_0\$ [ref. 10] fue entrenado para speech, no para canto polifónico). ¿Se normalizó por dominio de entrenamiento? Si no, ¿cómo se justifica el ranking de la Tabla II?"

3. Sección III.B — cómputo del SSM

Dónde: La frase *"Euclidean distance between downsampled feature vectors combining pitch (converted to MIDI scale) and normalized Root Mean Square (RMS) energy"*.

Acción: Encierra en un círculo "MIDI scale" y "RMS energy".

Comentario al margen:

"Pitch en MIDI (rango ~24–96) vs. RMS normalizada (rango 0–1). Sin normalización por componente, la distancia euclidiana está dominada por pitch en dos órdenes de magnitud. La energía es matemáticamente irrelevante en el SSM. ¿Qué ponderación o normalización (z-score, min-max) se aplicó? Debe explicitarse, porque condiciona toda la detección de fronteras."

4. Sección III.D — Ecuaciones (1) y (2) ⚠ BUG LÓGICO

Dónde: Las dos ecuaciones completas. Encierra los operadores $\vee$ (el "o" lógico) en ambas.

Acción: Encierra con rojo ambos símbolos $\vee$ en la Ecuación (1) y en la Ecuación (2).

Comentario al margen:

¡Inconsistencia lógica! Un segmento con pitch ascendente en la ventana terminal ($\int df_0/dt > \varepsilon$) Y energía baja ($\bar{E} < \tau_e$) satisface simultáneamente la condición de A (por el primer disyunto de la Ec. 1) y la de C (por el segundo disyunto de la Ec. 2). Las condiciones NO son mutuamente excluyentes. El paper no define regla de precedencia ni en III.D ni en el Algoritmo 1. La salida del clasificador queda INDEFINIDA para un subconjunto no trivial de entradas. CORREGIR: especificar precedencia explícita, o reescribir las condiciones como conjunciones disjuntas."

5. Sección III.D — Ecuación (1), parámetro ε

Dónde: El símbolo ε en la Ecuación (1).

Acción: Enciérralo en un círculo y traza una flecha hacia la Tabla I (página siguiente), donde aparece "*Pitch Slope Threshold $\varepsilon = 0.15$* ".

Comentario al margen:

"¿Unidades de ε ? La integral $\int (df_0/dt)dt$: ¿se evalúa en MIDI-s? ¿En semitonos acumulados? ¿En Hz-s? El valor 0.15 no es interpretable ni replicable sin unidades. Mismo problema con la magnitud que compara la integral."

6. Sección III.E — Algoritmo 1, línea 1 ⚠ CONTRADICCIÓN INTERNA

Dónde: Línea 1 del pseudocódigo: " $V \leftarrow SourceSeparation(X, Demucs)$ ".

Acción: Subráyala con doble línea y escribe "CONTRADICCIÓN" al lado. Traza una flecha hacia la Tabla II (filas 4 "CREPE" y 8 "Demucs+CREPE").

Comentario al margen:

¡Contradicción interna! La línea 1 aplica Demucs INCONDICIONALMENTE a toda entrada X , antes de cualquier ramificación por E_{type} . Pero la Tabla II reporta 'CREPE' (fila 4) y 'Demucs + CREPE' (fila 8) como configuraciones distintas. Si Demucs se aplica siempre, las filas 4 y 8 miden lo mismo y una sobra. Si no se aplica siempre, el Algoritmo 1 está mal escrito. Aclarar y corregir consistentemente."

7. Sección III.E — Algoritmo 1, línea 6 y Tabla I

Dónde: Línea 6 del pseudocódigo: "*if prob(s_i) < τ_{voicing} then Sfunc[i] $\leftarrow X$* ". En la Tabla I, fila "*Voicing Threshold* | τ_{voicing} | 0.5".

Acción: Encierra ambas ocurrencias de τ_{voicing} (0.5) y únelas con una flecha.

Comentario al margen:

"Se aplica UN único umbral de voicing (0.5) a las salidas de 8 extractores distintos. Estos extractores NO producen confianzas calibradas en la misma escala: unos usan probabilidades de modelo (CREPE), otros flags derivados (pYIN), otros scores no calibrados. El umbral universal sesga la asignación a la clase X de forma sistemáticamente distinta por extractor, confundiendo la comparación de la Tabla II. ¿Por qué no un umbral por extractor calibrado en validación?"

8. Sección III.E — Algoritmo 1 completo

Dónde: El bloque completo del Algoritmo 1 (líneas 1 a 12).

Acción: Traza un corchete vertical que abarque las líneas 1→4→5→9 y escribe "PIPELINE SECUENCIAL SIN CORRECCIÓN" al lado.

Comentario al margen:

"El pipeline es estrictamente secuencial: separación $\rightarrow$ extracción de f_0 $\rightarrow$ SSM $\rightarrow$ fronteras $\rightarrow$ clasificación. La Sección IV.E reconoce errores en cascada, pero solo cualitativamente. Se requiere ablación por etapa que aísle dónde se origina la degradación de retrieval: ¿en la separación? ¿en la extracción de f_0 ? ¿en el SSM? ¿en el clasificador? Sin esa descomposición no es posible interpretar las diferencias entre extractores en la Tabla II."

9. Sección IV.A — tamaño del dataset

Dónde: La frase "*a curated corpus of 80 pairs of musical works (160 tracks in total)*".

Acción: Enciérrela en un rectángulo y escribe "n=80" al margen.

Comentario al margen:

"Con n=80 pares, diferencias de 1–3 puntos de MRR en la Tabla II son probablemente indistinguibles del ruido muestral. Además, el diseño original—acústico fija la dirección de la variación tímbrica y no cubre casos reales de CSI (cambios de tonalidad, reordenamientos estructurales, covers instrumentales). Las conclusiones sobre 'invariancia estructural' deben acotarse a este escenario específico, o ampliarse a Covers80/Da-Tacos como los propios autores mencionan en Future Work."

10. Sección IV.B — justificación de hiperparámetros

Dónde: Los tres ítems numerados 1)–3) que justifican los hiperparámetros. Encierra la palabra "*optimal*" en el ítem 2.

Comentario al margen:

"La palabra 'optimal' implica selección sobre los datos. No se reporta partición train/dev/test ni held-out. Si los umbrales ε , τ_e , δ se ajustaron sobre los mismos 80 pares

de la Tabla II, los resultados están inflados por construcción. Pido: (a) explicitar el procedimiento de tuning, y (b) si no hubo held-out, repartir el corpus y rehacer, o reportar superficie de sensibilidad (MRR vs ϵ , τ_e) que muestre estabilidad."

11. Sección IV.B — ítem 3, justificación de δ ⚠ ERROR FACTUAL

Dónde: La frase "*This window provides sufficient frames for a stable linear regression of the f_0 slope*" en el ítem 3 de la justificación de hiperparámetros. Traza una flecha hacia las Ecuaciones (1) y (2).

Comentario al margen:

"¿Regresión lineal o integral? La justificación dice 'linear regression', pero las Ecs. (1) y (2) usan $\int (df_0/dt)dt$, que algebraicamente se reduce a $f_0(t_{end}) - f_0(t_{end} - \delta)$ y NO es una regresión. Si se implementó regresión, las ecuaciones deben reescribirse. Si se implementó la integral, la justificación del ítem 3 no aplica y debe corregirse. Aclarar la operación real."

12. Tabla II — columna DTW, valor RMVPE

Dónde: Columna DTW de la Tabla II. Encierra en rojo el valor **0.8773** en la fila de RMVPE.

Comentario al margen:

"Valores de DTW abarcan DOS ÓRDENES DE MAGNITUD: RMVPE = 0.8773 vs. resto = 20.41–49.30. No se especifica si DTW se reporta como distancia o similitud, ni normalización, ni unidades. El valor 0.8773 sugiere o bien normalización distinta solo en esa fila, o error de transcripción. Aclarar definición operacional y verificar el valor."

13. Tabla II — toda la tabla

Dónde: La Tabla II completa. Traza un rectángulo alrededor de toda la tabla y márcala con "FALTAN IC".

Comentario al margen:

"Toda la tabla reporta valores puntuales: sin intervalos de confianza, sin desviación estándar, sin tests pareados entre filas. Con $n=80$ y diferencias de pocos puntos entre métodos, la mayoría del ranking podría ser estadísticamente indistinguible. Reportar bootstrap CI al 95% sobre MRR y Top-5, y tests pareados (bootstrap pareado o Wilcoxon) entre al menos los métodos top. Sin esto, 'SPICE > FCN- f_0 ' no es defendible."

14. Tabla II — ausencia de baseline externo

Dónde: Tabla II. Escribe al pie de la tabla (o en el margen inferior):

Comentario al margen:

"La tabla compara 8 variantes del método propuesto ENTRE SÍ, pero no contra ningún sistema CSI estándar de referencia. Sin al menos un baseline externo (e.g., chroma-based SSM, coberturas tonales) sobre los mismos 80 pares, los valores absolutos de MRR y Top-5 no son contextualizables. Incluir baseline externo bajo el mismo protocolo."

15. Sección IV.E — hipótesis de "structural homogenization"

Dónde: El párrafo que comienza con "*This suggests a phenomenon of structural homogenization...*" y el párrafo siguiente. Encierra la frase "structural homogenization".

Comentario al margen:

"Hipótesis post-hoc no falsable con los datos presentados. No se reporta: entropía de secuencias generadas, tasa de colisión inter-pista, distribución de similitudes entre pares NO coincidentes. La diferencia clave (Avg. LCS 84.94% FCN- f_0 vs. 83.59% SPICE) es 1.35 puntos porcentuales sobre $n=80$. Sin intervalos de confianza, esa diferencia podría ser RUIDO (ver comentario Tabla II). Soportar con métricas adicionales o atenuar la afirmación a 'hipótesis a verificar en trabajo futuro'."

16. Sección V — Conclusiones, claim de invariancia

Dónde: La frase *"while style, tempo, and instrumentation may change drastically in a cover version, the underlying functional logic of the melody often remains invariant"*.

Acción: Subráyala completamente.

Comentario al margen:

"Claim de invariancia general extraído de un experimento con variación tímbrica UNIDIRECCIONAL (original producido → cover acústico) donde el mejor sistema recupera correctamente en Top-5 solo el 15% de los casos. Acotar la conclusión al escenario evaluado, o presentar evidencia adicional sobre transposición, cambio de género, covers instrumentales."



COMENTARIOS FORMALES (para enviar a los autores)

Copia y pega esta sección en el formato de revisión de la revista/conferencia.

El abstract afirma que "*antecedent-consequent recognition shows promise as a structural fingerprint for musical audio*", pero el mejor MRR reportado en la Tabla II es 9.83% y el mejor Top-5 es 15%. Con un Top-5 de 15%, el 85% de las queries falla en recuperar la coincidencia en las primeras cinco posiciones. Solicito reformular el abstract para que la afirmación cualitativa sea consistente con la magnitud cuantitativa, o presentar el sistema explícitamente como prueba de concepto preliminar.

Comentario 2 — Heterogeneidad de extractores (Sección III.A)

Los ocho extractores comparados fueron diseñados para tareas distintas: algunos para audio monofónico, otros para melodía predominante en polifonía, y FCN- f_0 [ref. 10] específicamente para pitch estimation en señales de habla. Aplicarlos sobre audio musical polifónico sin controlar por estas diferencias de dominio compromete la validez de la comparación. Solicito aclarar si se realizó alguna normalización o calibración por dominio de entrenamiento. En caso contrario, justificar el ranking de la Tabla II bajo estas condiciones.

Comentario 3 — Escala de características en el SSM (Sección III.B)

Se combina pitch en escala MIDI (rango aproximado 24–96) con RMS normalizada (rango 0–1) en un único vector sobre el que se aplica distancia euclidiana. Sin normalización por componente (z-score o min-max), la distancia está dominada por pitch en aproximadamente dos órdenes de magnitud, haciendo que la contribución de la energía al SSM sea matemáticamente despreciable. Solicitamos explicitar qué ponderación o normalización se aplicó antes del cómputo de distancia, ya que esto condiciona toda la detección de fronteras estructurales.

Comentario 4 — Condiciones de clasificación no mutuamente excluyentes (Sección III.D, Ecuaciones 1 y 2) ⚠ CRÍTICO

Tal como están definidas, las condiciones para Antecedente (Ec. 1) y Consecuente (Ec. 2) **no son mutuamente excluyentes**. Un segmento con pitch ascendente en la ventana terminal ($\int df_0/dt > \epsilon$) y simultáneamente energía baja ($\bar{E} < \tau_e$) satisface la condición de Antecedente por el primer disyunto de la Ecuación (1) y la de Consecuente por el segundo disyunto de la Ecuación (2). Ni la Sección III.D ni el Algoritmo 1 especifican regla de precedencia para este caso, dejando la salida del clasificador indefinida sobre un subconjunto no trivial de entradas. **Esto debe corregirse antes de cualquier interpretación de los resultados:** especificar precedencia explícita, reemplazar los operadores or por una regla de decisión ponderada, o reescribir como conjunciones disjuntas.

Comentario 5 — Unidades del umbral ϵ (Sección III.D, Ecuación 1, Tabla I)

No se especifican las unidades de $\epsilon = 0.15$. Dado que pitch se convierte a escala MIDI (Sección III.B), es necesario aclarar si la integral $\int df_0/dt \cdot dt$ se evalúa en MIDI-s, en semitonos acumulados, en Hz-s, o en otra unidad. Sin esta información, el valor 0.15 no es interpretable ni el experimento replicable. Lo mismo aplica a la magnitud que se compara en la integral.

Comentario 6 — Contradicción entre Algoritmo 1 y Tabla II (Sección III.E, línea 1) ⚠ CRÍTICO

La línea 1 del Algoritmo 1 aplica Demucs **incondicionalmente** a la entrada X : $V \leftarrow \text{SourceSeparation}(X, \text{Demucs})$. Sin embargo, la Tabla II presenta "CREPE" (fila 4) y "Demucs + CREPE" (fila 8) como configuraciones distintas. Existe una contradicción experimental: o bien Demucs se aplica siempre (y entonces las filas 4 y 8

miden lo mismo), o bien no se aplica siempre (y entonces el Algoritmo 1 está incorrectamente especificado). Solicitamos aclarar y corregir consistentemente.

Comentario 7 — Umbral de voicing universal (Sección III.E, Algoritmo 1, Tabla I)

Se aplica un único umbral $\tau_{\text{voicing}} = 0.5$ a las salidas de probabilidad de voicing de los ocho extractores. Sin embargo, estos extractores no producen valores de confianza calibrados en la misma escala ni con la misma semántica: algunos generan probabilidades bayesianas, otros scores de confianza no calibrados. Aplicar el mismo umbral a todos sesga la asignación de segmentos a la clase X de forma sistemática y diferenciada por extractor, confundiendo la comparación de la Tabla II. Solicitamos justificar el uso de un umbral universal frente a umbrales por extractor calibrados en un conjunto de validación.

Comentario 8 — Ausencia de ablación por etapa del pipeline (Sección III.E)

El pipeline del Algoritmo 1 es estrictamente secuencial y la Sección IV.E reconoce explícitamente que los errores se propagan en cascada. Sin embargo, esta discusión es únicamente cualitativa. Para un trabajo de nivel Q1 se espera al menos un estudio de ablación que descomponga el pipeline por etapas —separación, extracción de f_0 , segmentación SSM, clasificación por reglas— midiendo individualmente dónde se origina la degradación del retrieval. Sin esta descomposición, no es posible interpretar si las diferencias entre extractores en la Tabla II provienen de la calidad del pitch, de errores en la segmentación, o de fallas en el clasificador.

Comentario 9 — Tamaño y representatividad del dataset (Sección IV.A)

El corpus de 80 pares original→acústico impone dos limitaciones: (1) con $n=80$, diferencias de 1–3 puntos de MRR entre métodos son probablemente indistinguibles del ruido muestral; (2) el diseño fija la dirección de la variación tímbrica (producido→acústico) y no cubre casos reales de CSI como cambios de tonalidad, reordenamientos estructurales o covers instrumentales. Las conclusiones sobre invariancia estructural deben acotarse explícitamente al escenario evaluado, o ampliarse a benchmarks estándar como Covers80 o Da-Tacos que los propios autores mencionan en la Sección V.

Comentario 10 — Sobreajuste de hiperparámetros (Sección IV.B)

La Sección IV.B utiliza el término "*optimal*" para describir los valores de ϵ , τ_e y δ , lo cual implica selección sobre los datos. No se reporta partición train/dev/test ni conjunto held-out. Si estos umbrales se ajustaron sobre los mismos 80 pares utilizados en la Tabla II, los resultados de evaluación están inflados por construcción. Solicitamos: (a) explicitar el procedimiento de tuning, y (b) si no existió held-out, rehacer la evaluación con una partición adecuada, o alternativamente reportar una superficie de sensibilidad (MRR vs. ϵ , τ_e) que demuestre estabilidad de los resultados frente a la elección de hiperparámetros.

Comentario 11 — Inconsistencia entre justificación e implementación de δ (Sección IV.B, Ecuaciones 1-2) ⚠️ CRÍTICO

La justificación del ítem 3 de la Sección IV.B afirma que $\delta = 200$ ms proporciona "*sufficient frames for a stable linear regression of the f_0 slope*". Sin embargo, las Ecuaciones (1) y (2) computan una integral $\int_{t_{\text{end}}-\delta}^{t_{\text{end}}} (df_0/dt) dt$, que algebraicamente se reduce a la diferencia $f_0(t_{\text{end}}) - f_0(t_{\text{end}}-\delta)$ y **no constituye una regresión lineal**. Solicitamos aclarar cuál es la operación

efectivamente implementada y, en su caso, reescribir las ecuaciones o la justificación para que sean consistentes entre sí.

Comentario 12 — Anomalía en la métrica DTW (Tabla II)

La columna DTW de la Tabla II presenta valores que abarcan dos órdenes de magnitud entre extractores: RMVPE reporta 0.8773, mientras que el resto oscila entre 20.41 y 49.30. La Sección IV.C describe DTW como una métrica de alineación elástica sobre el contorno de f_0 , pero no especifica si se reporta como distancia o como similitud, ni la normalización aplicada, ni las unidades. El valor anómalo de RMVPE sugiere o bien una normalización distinta solo en esa fila, o un error de transcripción. Solicitamos aclarar la definición operacional de DTW y verificar la consistencia de los valores reportados.

Comentario 13 — Ausencia de intervalos de confianza (Tabla II) ⚠ CRÍTICO

Toda la Tabla II reporta estimaciones puntuales de rendimiento sin intervalos de confianza, sin desviación estándar y sin tests de significancia pareados entre filas. Con $n=80$ queries y diferencias de pocos puntos porcentuales entre la mayoría de los métodos, el ranking completo podría ser estadísticamente indistinguible. Solicitamos reportar intervalos de confianza bootstrap al 95% sobre MRR y Top-5, así como tests pareados (bootstrap pareado o Wilcoxon signed-rank) entre al menos los tres mejores métodos.

Comentario 14 — Ausencia de baseline externo (Tabla II, Sección IV)

La Tabla II compara exclusivamente variantes del método propuesto entre sí, sin incluir ningún sistema CSI de referencia estándar (e.g., coberturas basadas en chroma, MFCC con DTW). Sin al menos un baseline externo aplicado a los mismos 80 pares bajo el mismo protocolo experimental, los valores absolutos de MRR y Top-5 no son contextualizables y la magnitud real de la contribución no es evaluable. Solicitamos incluir al menos un baseline reproducible.

Comentario 15 — Hipótesis de "homogeneización estructural" no verificada (Sección IV.E)

La hipótesis de que FCN- f_0 produce "*structural homogenization*" se formula para explicar por qué tiene mayor LCS pero menor MRR que SPICE. Sin embargo, no es falsable con los datos presentados: no se reporta la entropía de las secuencias generadas, ni la tasa de colisión entre pares no coincidentes, ni la distribución de similitud entre pistas no emparejadas. Adicionalmente, la diferencia en Avg. LCS entre FCN- f_0 (84.94%) y SPICE (83.59%) es de solo 1.35 puntos porcentuales, magnitud que sin intervalos de confianza podría ser ruido muestral. Solicitamos: (a) soportar esta hipótesis con métricas adicionales (entropía, colisiones inter-pista), o (b) atenuar la afirmación presentándola como hipótesis a verificar en trabajo futuro.

Comentario 16 — Claim de invariancia no respaldado (Sección V)

La conclusión de que "*while style, tempo, and instrumentation may change drastically in a cover version, the underlying functional logic of the melody often remains invariant*" se extrae de un experimento con variación tímbrica unidireccional (original producido → cover acústico) y donde el mejor sistema acierta en Top-5 solo en el 15% de los casos. Estas condiciones no respaldan una afirmación general de invariancia estructural. Solicitamos acotar explícitamente la conclusión al escenario evaluado, o presentar

evidencia experimental adicional sobre otros tipos de variación (transposición tonal, cambio de género, covers instrumentales).



NOTAS TÁCTICAS

Prioridad	Comentarios	Tipo
● Máxima	#4, #6, #11	Bugs objetivos — no admiten defensa
● Alta	#10, #13, #14	Estándares metodológicos mínimos (ML/Q1)
● Media	#3, #5, #7, #12	Solicitudes de aclaración técnica (sin musicología)

Si necesitas recortar por límite de espacio, prioriza: #4 → #6 → #13 → #11 → #10 (en ese orden).